Implementación de la Línea Base y Protocolo de Evaluación

Protocolo de evaluación de la línea base de fallas de discos duros (HDD)

Propósito y alcance de la decisión

El presente protocolo tiene como propósito evaluar una línea base destinada a ordenar las observaciones diarias anteriores a una falla de disco duro (HDD) de acuerdo con su riesgo relativo de falla. Este ordenamiento podría utilizarse como apoyo para la priorización de inspecciones y otras actividades de mantenimiento. La métrica principal utilizada es el índice de concordancia de Harrell (C-index), el cual evalúa la capacidad del modelo para ordenar correctamente las observaciones según su riesgo relativo. Esta métrica no representa una probabilidad calibrada de falla ni permite estimar directamente el beneficio neto asociado con la decisión de reemplazar un disco.

Datos y construcción del objetivo

La evaluación utiliza el archivo `failed_drive_histories.csv` como fuente de datos, en lugar de los archivos diarios originales. Para cada número de serie, se identifica la fecha

correspondiente al registro en el que `failure = 1`. Cada observación anterior a dicha fecha se utiliza como un instante de predicción del tiempo restante hasta la falla.

Las variables SMART 5, 187, 188, 197, 198, 199 y 9 se utilizan como variables predictoras. Las variables `serial_number`, `date` y `failure` no se incluyen como predictores. La fecha de falla y las fechas futuras se utilizan exclusivamente para construir la variable objetivo `duration`, definida como la diferencia entre la fecha de falla y la fecha de observación. El día correspondiente a la falla se excluye como instante de predicción para evitar que información disponible únicamente en el momento de la falla sea utilizada durante la predicción.

El conjunto de datos utilizado no contiene observaciones censuradas, debido a que todas las trayectorias incluidas en el archivo terminan en una falla registrada.

Estrategia de partición

La validación utiliza una estrategia *leave-one-drive-out* (LODO), en la cual todas las observaciones pertenecientes a un mismo número de serie se mantienen juntas. En cada pliegue, todas las observaciones de un HDD se asignan exclusivamente al conjunto de prueba, mientras que los demás HDD se utilizan para entrenamiento.

Esta estrategia evita dividir las observaciones de un mismo disco entre entrenamiento y prueba. No se utiliza una partición aleatoria por filas o por días debido a que las observaciones consecutivas de un mismo HDD presentan dependencia temporal. La inclusión de observaciones del mismo dispositivo en ambos conjuntos podría producir una estimación excesivamente optimista del desempeño.

Para cada pliegue, se verifica explícitamente que la intersección entre los números de serie presentes en entrenamiento y prueba sea vacía. Además, los procedimientos de imputación y

estandarización se ajustan exclusivamente utilizando las observaciones del conjunto de entrenamiento. Posteriormente, las transformaciones obtenidas se aplican al conjunto de prueba. El modelo de Cox tampoco recibe información correspondiente al HDD utilizado como prueba.

Métricas de evaluación y estimación de variabilidad

La métrica principal utilizada es el C-index de Harrell calculado para cada HDD de prueba. Esta métrica permite determinar si las observaciones a las cuales el modelo asigna un mayor riesgo relativo corresponden, de manera consistente, a observaciones con un menor tiempo restante hasta la falla. Por lo tanto, resulta apropiada para evaluar una decisión basada en el ordenamiento y priorización del riesgo.

Aunque el C-index puede utilizarse en presencia de datos censurados, esta característica no resulta necesaria en la evaluación actual debido a que el conjunto de datos no contiene observaciones censuradas. Los resultados se resumen mediante la media macro de los C-index correspondientes a los HDD evaluados, la desviación estándar entre discos y el rango de valores observado. La media macro asigna el mismo peso a cada HDD, independientemente del número de observaciones diarias disponibles para cada dispositivo.

Como medida adicional de variabilidad, se calcula un intervalo percentil bootstrap del 95 % para la media macro. El procedimiento utiliza 2,000 réplicas y remuestrea los HDD con reemplazo, en lugar de remuestrear individualmente las filas diarias. Esta unidad de remuestreo permite conservar la estructura agrupada de las observaciones pertenecientes a un mismo dispositivo.

No se utiliza *accuracy* como métrica porque el objetivo del modelo no corresponde a una clasificación binaria convencional con clases independientes de observaciones negativas y

positivas. Asimismo, el riesgo relativo estimado por el modelo de Cox no se interpreta como una probabilidad de falla.

Evidencia de prevención de fuga de información

El protocolo incorpora varios mecanismos destinados a prevenir la fuga de información. En primer lugar, la función de preparación de datos construye una única tabla de predicción por cada observación previa a la falla y excluye la fecha terminal de falla como instante de predicción. La lista de predictores se encuentra definida previamente y no incluye `serial_number`, `date` ni el indicador `failure`.

En segundo lugar, la estrategia LODO garantiza que un determinado número de serie se encuentre exclusivamente en el conjunto de entrenamiento o en el conjunto de prueba de cada pliegue, pero nunca en ambos. El script verifica esta condición antes del ajuste de cada modelo.

En tercer lugar, los parámetros de imputación y estandarización se calculan exclusivamente a partir de las observaciones de entrenamiento. Específicamente, `SimpleImputer.fit` y `StandardScaler.fit` reciben únicamente los datos de entrenamiento, mientras que para los datos de prueba se utiliza exclusivamente la operación `transform`. De esta manera, la información estadística del conjunto de prueba no interviene en el proceso de preparación del entrenamiento.

Finalmente, aunque la variable objetivo utiliza la fecha futura de falla para calcular la duración restante, dicha fecha no se proporciona al modelo como variable predictora. El archivo `landmark_dataset.csv` conserva la fecha, el número de serie y la duración con fines de

auditoría; sin embargo, el ajuste del modelo utiliza únicamente las variables SMART seleccionadas, la duración y el indicador de evento.

Resultados de la ejecución

Utilizando el archivo `failed_drive_histories.csv`, la semilla 2026 y 2,000 réplicas de bootstrap, el C-index macro obtenido mediante la estrategia *leave-one-drive-out* fue de **0.417**, con una desviación estándar entre HDD de **0.186** y un rango de **0.085 a 0.500**. El intervalo percentil bootstrap del 95 % para la media macro, realizando el remuestreo agrupado por HDD, fue **[0.251, 0.500]**.

Los valores individuales del C-index correspondientes a los cinco HDD fueron **0.085, 0.500, 0.500, 0.500 y 0.500**, respectivamente. La concentración de resultados en 0.500 es compatible con predicciones empatadas o con ausencia de capacidad de ordenamiento dentro de varias de las trayectorias evaluadas. En consecuencia, el resultado agregado no proporciona evidencia de un buen desempeño de ranking en la muestra disponible.

Estos resultados deben interpretarse con precaución debido al reducido número de unidades independientes. En particular, el intervalo bootstrap presenta una elevada inestabilidad al estar basado únicamente en cinco HDD. Por esta razón, los valores obtenidos deben considerarse descriptivos del archivo disponible y no como una estimación estadísticamente defendible del desempeño futuro del sistema.

El resultado completo de la ejecución se encuentra disponible en el archivo `baseline_output/baseline_results.json`.