Informe de Diagnóstico y Plan de la Siguiente Iteración

Diagnóstico del Cox Elastic Net a partir de curvas de aprendizaje

Método y alcance

Se calcularon curvas con cinco pliegues externos agrupados por `serial_number` y tres tamaños de entrenamiento: 25%, 50% y 100% de los seriales de entrenamiento disponibles en cada pliegue. Esto representa en promedio 20, 40 y 80 seriales de entrenamiento, con los mismos seriales de validación para cualquier tamaño dentro de cada pliegue.

Se graficó conceptualmente el C-index macro intra-serial en entrenamiento y validación para Cox baseline y Cox Elastic Net. El Elastic Net ajustó `penalizer` y `l1_ratio` dentro de cada submuestra de entrenamiento, usando validación agrupada interna. La comparación principal anidada ya registrada se conserva como la evaluación de rendimiento; estas curvas son diagnósticas. La media y desviación de validación corresponden a cinco medias de pliegue, no a intervalos de confianza poblacionales.

Curvas observadas

El C-index es más alto cuando el modelo ordena las observaciones de una trayectoria de modo que las de menor tiempo restante reciben mayor riesgo.

Seriales de entrenamiento (promedio)	Modelo	C-index train	C-index validación (media ± DE entre pliegues)	Ajustes convergentes
20	Cox baseline	0.618	0.624 ± 0.087	5/5
20	Cox Elastic Net	0.616	0.621 ± 0.090	5/5
40	Cox baseline	0.635	0.642 ± 0.079	5/5
40	Cox Elastic Net	0.616	0.634 ± 0.091	4/5
80	Cox baseline	0.654	0.641 ± 0.080	5/5

Seriales de entrenamiento (promedio)	Modelo	C-index train	C-index validación (media ± DE entre pliegues)	Ajustes convergentes
80	Cox Elastic Net	0.654	0.641 ± 0.080	5/5

Entre 40 y 80 seriales, la validación cambia −0.001 para el Cox baseline y **+0.007** para Elastic Net: ambas curvas están prácticamente planas en ese tramo. Con 80 seriales, la brecha train-validación es aproximadamente 0.013 para ambos métodos; no aparece una brecha grande que indique sobreajuste marcado. El Elastic Net no muestra una ventaja visible frente al Cox baseline.

En la comparación anidada de desempeño, ambos obtuvieron C-index **0.6408** en los mismos 50 seriales puntuables. La diferencia pareada fue **0.0000** (IC bootstrap 95%: **[0.0000, 0.0000]**). Además, 18 de los 50 C-index por serial fueron exactamente 0.5, es decir, sin ordenamiento mejor que los empates para esas trayectorias. En el punto del 50% de entrenamiento, uno de los cinco ajustes Elastic Net no convergió; se dejó como no puntuado.

Factor limitante

La evidencia apunta primero al planteamiento de evaluación/decisión, no a falta de capacidad del Elastic Net. El código calcula C-index dentro de cada serial con evento y no puntúa los seriales censurados en prueba. Eso mide el orden de días dentro de un HDD; no mide si el sistema pone un HDD que fallará antes que otro HDD, ni una probabilidad de falla en un horizonte operativo. Si la decisión es priorizar discos para inspección o reemplazo, el objetivo y la métrica actuales no evalúan directamente esa decisión.

Posible limitante	Diagnóstico basado en la evidencia disponible
Capacidad del modelo	**No parece dominante en esta comparación.** Cox y Elastic Net comparten la misma curva y el mismo resultado anidado; a 80 seriales la brecha train-validación es solo ~0.013. Esto no descarta que otro modelo no lineal ayude después de corregir el objetivo.
Cantidad de datos	**No parece explicar una mejora media grande en el tramo observado.** La validación se estabiliza entre 40 y 80 seriales. Aun así, solo hay 100 seriales en

Posible limitante	Diagnóstico basado en la evidencia disponible
	esta ejecución; más unidades independientes podrían reducir incertidumbre, aunque la curva no promete un salto de desempeño.
Calidad de datos	**No se puede declarar como causa principal con estas curvas.** Un ajuste Elastic Net de cinco falló en el punto de 40 seriales y otras configuraciones de baja penalización fallaron en la búsqueda previa. Eso identifica fragilidad de optimización en algunos ajustes, pero no prueba por sí solo errores o mala calidad de datos SMART. Hace falta un perfil de faltantes, variación, duplicados y fechas.
Planteamiento del problema	**Limitante principal observable.** El score es intra-serial y excluye censurados de la métrica de prueba; por lo tanto no responde al ranking entre discos o al riesgo en un plazo de decisión. La curva estable no corrige esa desalineación.

La calidad de SMART queda sin diagnóstico concluyente; tampoco se atribuye la meseta a falta de capacidad. La conclusión prioriza corregir qué se predice y cómo se evalúa antes de aumentar complejidad o recopilar volumen sin una decisión alineada.

Tres experimentos prioritarios

1. Alinear predicción y decisión operativa

Hipótesis: la limitación principal es que el C-index intra-serial no representa la decisión de priorizar un HDD frente a otros.

Cambio: definir antes del análisis un horizonte fijo (por ejemplo, falla en 30 días desde un landmark SMART predefinido), mantener una predicción por serial en ese landmark y evaluar por HDDs completamente separados. Incluir censura correctamente; puntuar entre HDDs y no solo dentro de un serial.

Regla de decisión: aceptar que el reencuadre aporta valor predictivo si, en prueba agrupada, la mejora frente a una política/base de referencia es al menos **0.03** en AUC dependiente del tiempo o C-index a ese horizonte, el IC bootstrap pareado por serial excluye cero y el

Brier/calibración no empeora. Si no se cumplen estos criterios, no se afirma utilidad de priorización aunque el C-index intra-serial sea superior a 0.5.

2. Auditar calidad y señal de SMART

Hipótesis: la cobertura incompleta o falta de variación de algunos SMART reduce la señal que podría aprender el modelo.

Cambio: medir por columna y por serial faltantes, valores constantes, duplicados de fecha/serial y fechas inválidas; comparar el pipeline actual con una variante que excluya predictores con mala cobertura según un umbral predefinido. Mantener los mismos pliegues agrupados.

Regla de decisión: considerar calidad como limitante si al menos 20% de las filas elegibles carece de tres o más predictores SMART, o si más de la mitad de los predictores no varía en la mayoría de seriales; atribuir mejora a la limpieza solo si el C-index del experimento 1 mejora **≥0.03** y el IC pareado por serial excluye cero. Si no se cumple cobertura problemática o la limpieza no cambia la métrica, descartar calidad como limitante principal.

3. Probar si hace falta más capacidad

Hipótesis: tras alinear el objetivo y auditar predictores, la forma proporcional/lineal de Cox aún limita la predicción.

Cambio: comparar Elastic Net con una alternativa no lineal de supervivencia (por ejemplo, Random Survival Forest) usando el objetivo, seriales, partición externa y métrica del experimento 1 idénticos. Ajustar el modelo alternativo solo en validación interna agrupada.

Regla de decisión: considerar que la capacidad de Cox es insuficiente solo si la alternativa mejora el C-index/AUC del horizonte en **≥0.03**, el IC bootstrap pareado por serial excluye cero, y calibración/Brier no empeoran. Si no hay esa mejora, descartar complejidad adicional y mantener Cox por su mayor interpretabilidad.