Informe de Evaluación con Incertidumbre y Segmentos

Gabriel Rios
MAI 700

Desempeño, incertidumbre y calibración del predictor de fallas de discos duros (HDD)

Resumen

La evaluación realizada no demuestra una mejora del modelo de riesgos proporcionales de Cox con Elastic Net respecto al modelo de baseline. En una validación anidada de cinco pliegues, agrupada por número de serie, ambos modelos obtuvieron un índice de concordancia macro (C-index) de 0.6408 sobre los mismos 50 discos duros puntuables. La diferencia pareada entre ambos modelos fue de 0.0000. El intervalo bootstrap del 95 % para esta diferencia fue [0.0000, 0.0000], debido a que los resultados por número de serie fueron idénticos en esta ejecución. La ejecución no evaluó la calibración de las probabilidades ni estableció un umbral para activar alertas, inspecciones o reemplazos.

Datos y diseño de evaluación

El conjunto de datos utilizado fue compuesto por 100 números de serie y 7,601 observaciones. De los 100 discos incluidos, 50 presentaron una falla observada y los otros 50 quedaron censurados durante el período de observación.

La evaluación se realizó mediante una validación externa de cinco pliegues, estratificada y agrupada por número de serie. La selección de hiperparámetros se llevó a cabo mediante pliegues internos agrupados, de manera que las observaciones pertenecientes a un mismo disco permanecieran dentro de una misma partición.

El cálculo del C-index se efectuó sobre los 50 discos con eventos observados. La incertidumbre de la media macro se estimó mediante 2,000 réplicas bootstrap agrupadas por

número de serie. Este procedimiento conserva el disco duro como unidad independiente de remuestreo.

El modelo de referencia correspondió a un modelo de Cox con penalización L2, configurado mediante penalizer = 1.0 y l1_ratio = 0. El modelo Elastic Net seleccionó sus hiperparámetros dentro de los datos de entrenamiento. El modelo final reajustado utilizó una penalización de 1.0 y un parámetro de mezcla de l1_ratio = 0.25.

Desempeño en comparación con la línea base

La tabla presenta los resultados de la evaluación comparativa de los modelos y la diferencia entre sus índices de concordancia.

Comparación del desempeño de los modelos de Cox

Modelo o comparación	**C-index macro**	**IC bootstrap del 95 %**	**HDD puntuables**
Cox baseline (L2)	0.6408	[0.5765, 0.7032]	50
Cox Elastic Net	0.6408	[0.5755, 0.7042]	50
Diferencia pareada (Elastic Net − baseline)	0.0000	[0.0000, 0.0000]	50

La desviación estándar del C-index entre los números de serie para el modelo Elastic Net fue de 0.2307. La igualdad de los resultados por disco explica el intervalo bootstrap degenerado de la diferencia entre los modelos. No obstante, esta igualdad no demuestra que ambos modelos sean equivalentes en otras muestras o condiciones de evaluación.

El C-index mide la capacidad de ordenamiento relativo del tiempo hasta el evento entre observaciones comparables con una falla observada. No representa una probabilidad de falla, no permite calibrar directamente los días restantes y no mide por sí solo la capacidad de ordenar el riesgo entre discos diferentes. Aunque los 50 discos censurados participaron en el ajuste del modelo, no se incluyeron en el cálculo de la media del C-index reportada.

Incertidumbre de la estimación del tiempo hasta la falla

El script predecir_falla_hdd.py devuelve la mediana de la curva de supervivencia estimada a partir de los valores SMART proporcionados. Esta mediana corresponde al tiempo en el que la supervivencia estimada por el modelo desciende hasta 0.50, condicionada a los parámetros del modelo y a los datos utilizados durante el entrenamiento.

El artefacto actual no calcula intervalos de confianza o de predicción para esta mediana ni incluye una evaluación de la cobertura de dichos intervalos. En consecuencia, cada resultado debe interpretarse como una estimación puntual cuyo nivel de incertidumbre individual no ha sido cuantificado. El intervalo de confianza del C-index presentado anteriormente no sustituye una medida de incertidumbre para las predicciones individuales del tiempo hasta la falla.

Cuando la curva de supervivencia no alcanza el valor de 0.50 dentro del horizonte evaluado, el programa no proporciona una mediana finita. Incluso cuando la mediana es finita, esta no representa una fecha garantizada de falla, sino una estimación condicionada al modelo y a los datos disponibles.

Calibración del modelo

La calibración no fue evaluada mediante los artefactos y las métricas generados en esta ejecución. El archivo experiment_results.json registra el C-index y los resultados de su estimación bootstrap, pero no contiene predicciones de supervivencia fuera de muestra por disco y horizonte temporal, puntuaciones de Brier, curvas de calibración ni comparaciones entre riesgos observados y predichos.

Por consiguiente, no existe evidencia suficiente para afirmar que una predicción de riesgo determinada, como una probabilidad de falla del 20 %, corresponda a una frecuencia observada cercana al 20 %.

Para evaluar la calibración, será necesario almacenar predicciones fuera de muestra de la probabilidad de falla antes de horizontes temporales previamente definidos. Posteriormente, deberán calcularse métricas apropiadas para datos de supervivencia, como la puntuación de Brier dependiente del tiempo, y realizarse comparaciones entre los resultados observados y predichos. Estas evaluaciones deberán considerar la censura mediante métodos estadísticos apropiados; por ejemplo, estimaciones de Kaplan–Meier dentro de grupos de riesgo.

La incertidumbre de las métricas de calibración deberá estimarse mediante un procedimiento bootstrap que remuestree números de serie completos. Asimismo, el modelo final reajustado con todos los datos puede utilizarse para generar predicciones, pero las predicciones realizadas sobre esos mismos datos no constituyen una evaluación independiente de su desempeño.

Conclusión

El modelo Cox Elastic Net no superó al modelo de referencia en la comparación realizada. Ambos obtuvieron un C-index macro de 0.6408 y presentaron los mismos resultados por número de serie, con una diferencia pareada de 0.0000. En ausencia de evidencia de una mejora útil, se mantiene la preferencia por el modelo de referencia debido a su mayor simplicidad.

Los resultados tampoco permiten interpretar las medianas estimadas de días restantes como predicciones calibradas ni justifican establecer un umbral operativo para la activación automática de alertas o reemplazos. Para avanzar hacia una aplicación operativa, será necesario evaluar las probabilidades de falla en horizontes temporales definidos, estudiar la calibración, cuantificar la incertidumbre de las predicciones individuales y considerar explícitamente los costos de las decisiones de mantenimiento.