Auditoría de IA Responsable y Mitigación

Gabriel Rios
MAI 700

Alcance y sistema evaluado

El sistema evaluado estima el tiempo mediano hasta la falla de un disco duro (HDD) mediante un modelo de riesgos proporcionales de Cox y siete atributos SMART normalizados: smart_5, smart_9, smart_187, smart_188, smart_197, smart_198 y smart_199.

La evaluación agrupada por número de serie incluyó 50 discos con fallas observadas. Cox Elastic Net obtuvo un C-index de 0.6408, con un intervalo bootstrap del 95 % de [0.5755, 0.7042]. La evidencia respalda únicamente un uso exploratorio para priorizar revisiones humanas; no justifica reemplazos automáticos ni garantiza estimaciones precisas de los días restantes.

Equidad

Definición y evaluación

Se adopta el criterio de equidad de desempeño por subgrupo, según el cual los errores y la utilidad del sistema deberían ser comparables entre grupos operativamente relevantes. Para evaluarlo, se deberán comparar el ordenamiento temporal, la calibración y los errores de riesgo por horizonte. La paridad de predicciones no es suficiente por sí sola, pues podría ocultar diferencias reales en las condiciones de los equipos.

Aunque el conjunto incluye fabricante, modelo, ubicación del centro de datos, clúster y otros identificadores, no se ha realizado un análisis de equidad por subgrupo. El C-index global de 0.6408 no demuestra paridad, y no hay métricas desglosadas que permitan confirmar o descartar disparidades. Las diferencias de firmware, fabricante y disponibilidad de telemetría podrían afectar el desempeño.

Mitigación y limitaciones

El script fue modificado para rechazar predicciones cuando faltan atributos SMART requeridos, identificando los campos ausentes. Esta medida evita generar estimaciones con entradas incompletas, pero no garantiza equidad, ya que la falta de telemetría podría variar entre grupos.

En una prueba de estrés que enmascaró aleatoriamente el 50 % de las celdas SMART, el C-index fue de 0.5700 para el modelo de referencia y de 0.5417 para Elastic Net. Con todos los atributos SMART ausentes, ambos obtuvieron 0.5000.

Se recomienda evaluar la cobertura y el C-index después de aplicar el rechazo, desglosando ambos resultados por grupo y utilizando intervalos bootstrap agrupados por número de serie. Una cobertura desigual también podría constituir una disparidad.

Privacidad y protección de datos

Datos y exposición

El archivo de entrenamiento contiene números de serie, fechas, fabricante, modelo, capacidad, indicadores de falla, atributos SMART e identificadores de infraestructura, como centros de datos, clústeres, *pods* y ranuras. No todos los campos son necesarios para entrenamiento especialmente los identificadores de infraestructura. Aunque el modelo utiliza siete atributos SMART, los archivos conservan información adicional que podría identificar activos y revelar datos operativos confidenciales.

Los valores SMART enviados podrían quedar expuestos en historiales de consola o registros. Por ello, deben excluirse de las entradas y registros los identificadores y campos innecesarios para la predicción.

Retención y protección

Se recomienda establecer plazos de conservación, limitar accesos y copias, y documentar la eliminación verificable de los datos y sus derivados.

La combinación de fechas, atributos SMART e identificadores podría revelar la condición o probabilidad de falla de equipos específicos. Se recomienda aplicar controles de acceso por roles o cifrado. No deberían publicarse predicciones individuales con números de serie o ubicaciones.

Riesgo normativo

Clasificación

La clasificación normativa es indeterminada y depende del contexto. El prototipo está orientado al mantenimiento predictivo de discos y no se ha documentado su uso para tomar decisiones automaticamente. Por tanto, el uso de aprendizaje automático no basta para clasificarlo como sistema de alto riesgo.

En la Unión Europea, un sistema dedicado exclusivamente al mantenimiento predictivo de HDD no parece encajar, por la finalidad descrita, en las categorías de alto riesgo del Reglamento de Inteligencia Artificial. Esta conclusión podría cambiar si se modifica su finalidad o se integra en un producto o proceso regulado. La clasificación debe verificarse con asesoría jurídica antes del despliegue.

Obligaciones y controles recomendados

Se recomienda:

1. Definir la finalidad y jurisdicción: documentar operadores, usuarios, decisiones apoyadas y límites de uso.
2. Gobernar los datos: registrar procedencia, calidad, permisos, retención y eliminación, minimizando los identificadores innecesarios.
3. Proteger los datos personales: cuando corresponda, establecer la base jurídica, cumplir las obligaciones de información y evaluar la necesidad de una evaluación de impacto de privacidad.
4. Documentar el modelo: conservar versiones, transformaciones, métricas, incertidumbre, limitaciones y usos prohibidos. También debe resolverse la discrepancia identificada entre el modelo de referencia serializado y los resultados agregados.
5. Mantener supervisión humana: registrar abstenciones y fallos, vigilar cambios en los datos y suspender el uso fuera del rango validado. No se recomiendan reemplazos automáticos con la evidencia actual.

Conclusión

El predictor presenta una capacidad moderada de ordenamiento temporal. La revisión identifica riesgos potenciales relacionados con la exposición de identificadores de infraestructura. La clasificación normativa requiere conocer la finalidad, jurisdicción y contexto de uso. Por tanto, el sistema debe mantenerse en una fase exploratoria con supervisión humana.