Ficha del Modelo y Declaración de Riesgo Residual

Sistema: predictor de tiempo hasta falla de discos HDD basado en Cox Elastic Net
Estado recomendado: prototipo para análisis y priorización con revisión humana; no aprobado para decisiones automáticas.

Resumen del sistema

El modelo ajusta una regresión de supervivencia Cox Elastic Net con siete predictores SMART normalizados: smart_5, smart_9, smart_187, smart_188, smart_197, smart_198 y smart_199. El programa de inferencia entrega la mediana modelada del tiempo hasta falla si la curva de supervivencia cruza 0.5; si no la cruza, no informa una mediana finita. La mediana es una estimación condicionada al modelo, no una fecha garantizada ni una probabilidad calibrada de falla.

Uso previsto

- Análisis exploratorio de telemetría de HDD.
- Apoyo para ordenar casos que una persona pueda revisar y priorizar para inspección, siempre dentro del rango operativo de esta ficha.
- Uso con las mismas definiciones, unidades, preprocesamiento y semántica de atributos SMART que los datos de entrenamiento.

La salida no debe ser la única base de una acción sobre un disco. La organización debe confirmar el estado del equipo y aplicar sus procedimientos de mantenimiento.

Usos fuera de alcance

- Reemplazo, apagado, garantía o compra automáticos basados en la mediana o en el score.
- Interpretar el score como probabilidad de falla o como riesgo absoluto entre discos.
- Prometer una fecha exacta o precisa de falla, o usar la salida como intervalo de confianza individual.
- Uso con todos los SMART ausentes, con cobertura degradada, valores inválidos o incoherencias en fechas, eventos y reglas de censura.
- Extrapolar a otros fabricantes, familias, firmware, convenciones SMART, periodos o poblaciones sin validación externa específica.
- Uso en decisiones sobre personas, empleo, crédito, servicios esenciales u otros fines no evaluados.

No existe un umbral validado de alarma o reemplazo. El 0.5 usado para hallar la mediana de supervivencia no es un umbral de decisión.

Datos de entrenamiento y evaluación

El conjunto usado para entrenamiento contiene 7601 observaciones de 100 seriales: 50 con falla observada y 50 censurados. Incluye fechas, indicador de falla, atributos SMART, fabricante/modelo y datos de ubicación e infraestructura. La unidad de separación y remuestreo fue el serial para evitar tratar observaciones del mismo HDD como independientes. La validación anidada usó cinco pliegues agrupados por serial; el C-index se calculó para 50 HDD con evento. La censura se definió con la última fecha observada y la falla con la primera fecha registrada con failure=1.

El predictor usa solo siete atributos SMART, aunque los archivos de análisis contienen identificadores y campos adicionales que requieren minimización y controles de acceso. No se documenta en los artefactos una política de retención de esos datos.

Resultados de evaluación

Evaluación	**Resultado**	**Interpretación y límite**
Cox baseline (L2), validación agrupada	C-index 0.6408; IC 95% [0.5765, 0.7032]	Ordenamiento temporal dentro de HDD con evento; no es calibración ni riesgo absoluto entre HDDs.
Cox Elastic Net, validación agrupada	C-index 0.6408; IC 95% [0.5755, 0.7042]	No mostró mejora sobre el baseline en esta comparación.
Diferencia pareada EN − baseline	0.0000	Los scores por serial fueron idénticos en esta ejecución.
Estrés: SMART intactos, modelos serializados	Baseline 0.6389; Elastic Net 0.6408	Diferencia pequeña entre baselines.
Estrés: 50% de celdas SMART ausentes	Baseline 0.5700 [0.5351, 0.6076]; EN 0.5417 [0.5038, 0.5774]	Sensibilidad a telemetría incompleta. Escenario sintético.
Estrés: todos los SMART ausentes	Ambos 0.5000	Ordenamiento aleatorio, equivalente a no tener señal útil en esta prueba sintética.

Rango operativo

Dentro del rango, con cautela

- HDD con el mismo modelo y protocolo de adquisición de los siete SMART normalizados usados por el modelo.
- Telemetría válida, completa en los siete atributos requeridos y comparable con el soporte de entrenamiento.
- Uso exploratorio o priorización para revisión humana. El umbral numérico de soporte no está definido todavía y debe calcularse antes de la integración.

Fuera del rango

- Entradas incompletas. Se implementó una mitigación y ahora se rechaza la predicción cuando faltan cualquiera de los atributos que requiere el modelo, en lugar de imputar silenciosamente esos valores en inferencia.
- Cobertura degradada comparable al escenario de 50% de celdas ausentes, salvo que una validación local específica demuestre desempeño aceptable.
- Otro fabricante, familia o protocolo no validado.
- Reemplazo automático, garantías, cortes de riesgo o fecha de falla precisa.
- Datos/eventos/seriales inconsistentes con las reglas de construcción y censura.

Consideraciones éticas

- Equidad: la definición elegida es comparabilidad del desempeño por subgrupo operativo. No se ha medido; promedios globales podrían ocultar disparidades por fabricante, firmware, datacenter o acceso desigual a telemetría y mantenimiento. Medir tanto cobertura (incluidas abstenciones) como desempeño por grupo.
- Supervisión humana: el resultado puede influir en prioridades de mantenimiento; una persona debe revisar contexto y telemetría y conservar autoridad para descartar la recomendación.
- Incertidumbre y comunicación: no presentar la mediana como fecha cierta ni score como probabilidad. La falta de calibración y de intervalos individuales limita decisiones sensibles al costo.
- Privacidad y seguridad: seriales, fechas y ubicaciones identifican activos y pueden revelar estado de infraestructura. Minimizar identificadores y restringir acceso.
- Riesgo normativo: la clasificación depende de jurisdicción, finalidad, despliegue y posibles vínculos con personas; documentar esos elementos antes de publicación o cambio de uso.

Declaración de riesgo residual

La mitigación de entradas incompletas no elimina los siguientes riesgos. Probabilidad se expresa cualitativamente porque no hay datos operativos para estimar frecuencia;

“desconocida” indica que tampoco hay base suficiente para asignar una categoría. La consecuencia describe el efecto plausible si ocurre el evento.

Riesgo que subsiste	**Probabilidad**	**Consecuencia posible**	**Señal o control posterior**
La telemetría cambia de distribución o semántica (firmware, modelo, sensores, protocolo)	Desconocida	Predicciones degradadas o engañosas; priorización incorrecta de HDD	Deriva de entradas por SMART, firmware y modelo; validación periódica y bloqueo fuera del soporte.
Los datos son completos pero incorrectos, retrasados o con unidades/definiciones distintas	Desconocida	La regla de ausencia no lo detecta; estimación incorrecta y acción de mantenimiento mal priorizada	Rangos, tipos, unidades, frescura, consistencia temporal y tasas de corrección.
Equidad desigual entre grupos operativos	Desconocida	Un grupo puede recibir peores estimaciones o más abstenciones, con mantenimiento tardío o recursos mal asignados	Cobertura, C-index y métricas por fabricante, firmware, datacenter y otros grupos acordados, con incertidumbre.
Censura, fechas o eventos mal registrados	Desconocida	Objetivo de supervivencia incorrecto y evaluación/modelo sesgados	Auditoría de etiquetas, eventos, fechas terminales y proporción de registros corregidos.
Mediana se interpreta como fecha cierta o riesgo absoluto	Posible	Reemplazos prematuros o tardíos, interrupción del servicio o costo evitable	Revisión de decisiones, auditoría de comunicaciones y prohibición de umbrales no validados.
Incertidumbre individual de la mediana no cuantificada	Posible	Usuario confía en una estimación puntual sin conocer su margen de error	Comunicar explícitamente ausencia de intervalo; no usar para fecha límite.

Riesgo que subsiste	Probabilidad	Consecuencia posible	Señal o control posterior
Retención excesiva o acceso indebido a datos/artefactos	Desconocida	Exposición persistente de telemetría e identificadores; incumplimiento de reglas aplicables	Inventario, permisos, plazos de borrado, copias y auditoría de acceso.
Desajuste entre artefactos, transformadores, código y métricas reportadas	Observado en parte	Resultado no reproducible o implementación distinta de la validada	Versiones de datos, código, transformadores y modelo; prueba de carga y score de referencia.
Uso ampliado o clasificación legal distinta a la supuesta	Desconocida	Obligaciones regulatorias incumplidas o daño por decisión fuera de finalidad	Revisión de finalidad, jurisdicción, usuarios, integración y vínculo con personas ante cada cambio.

La combinación de probabilidad desconocida y consecuencia operativa potencialmente alta justifica limitar el sistema a apoyo humano hasta disponer de validación temporal/externa, análisis por grupos, calibración y controles operativos.

Monitoreo posterior a publicación

La organización que despliegue el sistema debería asignar personas, umbrales de alerta y acciones de respuesta para, como mínimo, lo siguiente:

1. Proporción de solicitudes aceptadas/rechazadas y atributos SMART faltantes; desglosar por modelo de HDD, firmware, datacenter y fuente de datos. Investigar aumentos o diferencias entre grupos antes de volver a usar estimaciones.
2. Calidad y validez de entradas: unidades, rangos, valores imposibles, duplicados, datos obsoletos, cambios de esquema y consistencia de fechas/eventos. Rechazar entradas inválidas; no convertir errores de captura en ceros ni imputarlos sin evaluación.
3. Desempeño con resultados observados: cuando maduren fallas/censura, recalcular C-index con agrupación por serial; medir Brier/calibración y métricas en horizontes de decisión predefinidos. Asegurar una ventana con suficientes eventos y reportar limitaciones muestrales.

4. Equidad: cobertura y métricas por grupos pertinentes (por ejemplo, fabricante/modelo, firmware y datacenter), con intervalos y tamaño muestral. Investigar diferencias de calidad de datos y tasas de abstención, no solo promedios de predicción.
5. Uso e intervención: porcentaje de resultados revisados por una persona, decisiones tomadas, anulaciones, reemplazos, falsas alarmas, fallas omitidas y costos operativos. Confirmar que nadie use la mediana como fecha cierta o umbral automático.
6. Incidentes: registrar predicciones fallidas, discrepancias con inspecciones, cambios de proceso, exposición de telemetría, accesos anómalos y fallos del servicio; definir escalamiento, contención y suspensión.
7. Privacidad y retención: auditar permisos, logs, exportaciones, copias, plazo de conservación y borrado; evitar seriales/SMART en logs salvo necesidad aprobada y protegida.

La organización debe establecer antes del despliegue valores de alerta para deriva, desempeño, brecha entre grupos y tasa de abstención a partir de validación local y costos de operación. Si se rompe el rango validado, faltan resultados confiables o aparece una disparidad/incidente relevante, la acción segura es suspender el uso afectado, conservar revisión humana y revalidar antes de reanudarlo.