

Documentación de Datos y Línea Base

Ética

1. Ficha técnica del conjunto de datos

Nombre: Corpus de código fuente y documentación para generación automática de comentarios.

Propósito: El conjunto de datos se utilizará para desarrollar y evaluar una aplicación de inteligencia artificial capaz de generar comentarios y documentación a partir de código fuente.

Procedencia: Los datos principales procederán de repositorios públicos de código abierto que permitan su utilización para investigación y desarrollo de sistemas de inteligencia artificial. Se considerarán fuentes que utilicen licencias permisivas como **MIT License, Apache License 2.0 y BSD Licenses**. Como complemento, se podrán generar datos sintéticos que representen diferentes tipos de comentarios y documentación, incluyendo descripciones de funciones, parámetros, valores de retorno y explicaciones generales del código.

Método de recolección: Los ejemplos públicos se obtendrán mediante la selección y descarga de repositorios que cumplan los criterios de licencia establecidos. Posteriormente se extraerán fragmentos de código asociados con sus comentarios o documentación. Los datos sintéticos serán generados específicamente para complementar categorías que estén poco representadas en los datos públicos.

Licenciamiento y base de acceso: El uso de datos públicos estará condicionado a la licencia específica de cada repositorio. Se conservará la información de fuente, licencia y atribución. No se utilizarán datos cuya licencia no pueda verificarse. Los datos sintéticos serán generados para el proyecto y no dependerán de la licencia de un repositorio externo.

Tamaño previsto: El corpus inicial tendrá como meta aproximadamente **10,000 ejemplos código-documentación**. El tamaño final dependerá de la disponibilidad y calidad de las fuentes que cumplan los criterios de licencia.

Unidad de análisis: Cada registro representará un fragmento de código, como una función, método o clase, acompañado por comentarios o documentación que describan su comportamiento.

Uso previsto: Los datos se utilizarán para entrenamiento, validación y evaluación de modelos de generación de texto aplicado a código. No se utilizarán para tomar decisiones sobre personas ni para evaluar individuos.

2. Atributos sensibles, variables sustitutas y fuga de información

El proyecto no tiene como objetivo utilizar atributos personales. Sin embargo, los repositorios públicos pueden contener accidentalmente nombres de personas, correos electrónicos, nombres de usuarios, direcciones, claves, tokens u otra información incluida dentro del código o comentarios. Estos elementos serán identificados y eliminados o anonimizados cuando corresponda.

También se considerarán posibles **variables sustitutas**, como nombres de usuarios, organizaciones, repositorios o proyectos, cuando puedan revelar información personal innecesaria. Estos elementos no aportan directamente al objetivo de generar documentación y pueden introducir riesgos de privacidad.

El principal riesgo de **fuga de información** será la presencia del mismo código, repositorio o versiones muy similares tanto en entrenamiento como en prueba. Para reducirlo, la separación de los datos se realizará por repositorio cuando sea posible, en lugar de dividir aleatoriamente cada fragmento. También se buscarán duplicados y ejemplos altamente similares antes de realizar el modelado.

Otro posible riesgo sería utilizar documentación de referencia durante el entrenamiento y posteriormente evaluar el modelo con esa misma documentación o con versiones prácticamente idénticas. Este problema se evitará manteniendo un conjunto de prueba independiente.

3. Línea base ética y normativa

La aplicación propuesta se considera inicialmente de **bajo riesgo**, debido a que su función será asistir en una tarea de documentación de software y no tomar decisiones sobre personas, empleo, crédito, salud, educación u otros ámbitos de alto impacto.

Aun así, existen obligaciones importantes. El proyecto deberá respetar las condiciones de las licencias utilizadas, mantener la trazabilidad de las fuentes y evitar incorporar información personal, secretos, credenciales o contenido que no sea necesario para el objetivo del proyecto. Las salidas generadas deberán considerarse sugerencias y requerir revisión humana.

La aplicación también deberá comunicar sus limitaciones. Una explicación generada por IA puede ser incorrecta aunque parezca técnicamente válida. Por esta razón, el desarrollador será responsable de verificar la documentación antes de incorporarla a un proyecto.

4. Preparación de los datos

La preparación se realizará en el siguiente orden:

1. **Verificar las licencias** y conservar la procedencia de cada fuente.
2. **Eliminar archivos que no correspondan** al objetivo del proyecto.
3. **Detectar y eliminar duplicados** y ejemplos prácticamente idénticos.
4. **Detectar información sensible**, como correos, credenciales o tokens, y eliminarla o anonimizarla.
5. **Normalizar los formatos** de código y documentación.
6. **Clasificar los ejemplos** según lenguaje y tipo de documentación.
7. **Revisar la calidad** de los pares código-documentación.
8. **Incorporar los datos sintéticos** necesarios para cubrir categorías insuficientemente representadas.
9. **Separar entrenamiento, validación y prueba por repositorio**, cuando sea posible, para reducir fuga de información.
10. **Realizar un perfilado final** y verificar que no queden problemas críticos antes del modelado.